דוח מסכם

חיזוי כוונת רכישה של גולשים באתר מסחר מקוון

שם הסטודנטית: נעמה סקיטל

קורס: למידת מכונה

מרצה: ליעד גוטליב

תאריך הגשה: 28.07.2026

קישור לפרויקט ב-**GitHub**

https://github.com/naamaskital/Online_Shoppers_Purchase_Prediction_Project

תקציר מנהלים

מטרת הפרויקט היא לחזות האם ביקור באתר מסחר מקוון יסתיים ברכישה. המאגר כולל 12,330 ביקורים, אך רק 15.5% מהם הסתיימו ברכישה. לכן הדגש בהערכה היה על Precision, Recall, F1 ו-ROC AUC ולא על Accuracy בלבד. המודל המוביל היה Random Forest מאוזן, עם F1 של 0.6634 ו-ROC AUC של 0.9191. בנוסף נבדקו AdaBoost, PCA, SMOTE ושילוב PCA-SMOTE-KNN. הניסוי החדש העלה משמעותית את Recall של KNN, אך לא עבר את Random Forest.

1	תיאור הבעיה ומטרות הפרויקט
2	שאלות המחקר
3	תיאור מאגר הנתונים
4	חקירת הנתונים - Exploratory Data Analysis
5	כלים, מבנה הפרויקט ותהליך העבודה
6	עיבוד מוקדם ומניעת דליפת מידע
7	האלגוריתמים והשיטות שנבדקו
8	מדדי ההערכה
9	השוואת המודלים המרכזית
10	ניתוח חוסר האיזון
11	חשיבות המאפיינים
12	ניסיון לשיפור Random Forest
13	AdaBoost ו-PCA לצורך המחשה
14	ניסוי PCA, SMOTE ו-KNN
15	כוונון PCA, SMOTE ו-KNN
16	דיון כולל, אתגרים ומגבלות
17	מסקנות

1. תיאור הבעיה ומטרות הפרויקט

אתרי מסחר מקוון אוספים מידע על התנהגות המשתמש במהלך הביקור: מספר הדפים שבהם צפה, זמן השהייה בכל סוג דף, שיעור הנטישה, שיעור היציאה, מקור התנועה, החודש וסוג המבקר. מידע זה מאפשר לנסות לחזות האם ביקור מסוים יסתיים ברכישה.

הבעיה היא בעיית סיווג בינארי: Revenue=True מציין ביקור שהסתיים ברכישה, ו-Revenue=False מציין ביקור שלא הסתיים ברכישה.

חיזוי כזה יכול לסייע בזיהוי משתמשים בעלי סיכוי גבוה לבצע רכישה, בהתאמת הצעות שיווקיות, בתיעדוף פניות ובהבנת הגורמים ההתנהגותיים הקשורים להשלמת עסקה.

- מטרה ראשית - לבנות מודל המסווג ביקורים לרכישה או ללא רכישה.
- מטרה השוואתית - להשוות בין כמה משפחות מודלים ולא לבחור מראש אלגוריתם אחד.
- מטרה יישומית - להתמודד עם חוסר האיזון ולתת חשיבות לזיהוי מחלקת הרכישה.
- מטרה מחקרית - לנתח אילו מאפיינים משפיעים על החיזוי ומה קורה כאשר משנים את תהליך המידול.

1. האם ניתן לחזות רכישה על סמך נתוני הביקור באתר?
2. איזה אלגוריתם משיג את האיזון הטוב ביותר בין Precision ל-Recall?
3. כיצד חוסר האיזון בין המחלקות משפיע על Accuracy, Recall ו-F1?
4. האם class weighting משפר את זיהוי מחלקת הרכישה?
5. אילו מאפיינים הם המשמעותיים ביותר עבור Random Forest?
6. האם Grid Search ושינוי סף ההחלטה משפרים את Random Forest?
7. האם AdaBoost משיג ביצועים טובים יותר מהמודלים המרכזיים?
8. מה ניתן ללמוד מהקרנת PCA לשני ממדים?
9. האם PCA מפחית את בעיית הממדיות של KNN?
10. האם SMOTE משפר את ה-Recall של KNN?
11. האם השילוב PCA-SMOTE-KNN טוב יותר מכל רכיב בנפרד?
12. האם כוונון מספר הרכיבים, מספר השכנים ושיטת המשקולות משפר את המודל המשולב?

הפרויקט מבוסס על מאגר Online Shoppers Purchasing Intention. המאגר כולל 12,330 ביקורים באתר, 17 מאפייני קלט ועמודת מטרה אחת בשם Revenue. כל שורה מייצגת ביקור אחד.

טבלה 1: מאפיינים כלליים של המאגר

רכיב	תיאור
מספר דוגמאות	12,330 ביקורים
מספר מאפייני קלט	17
משתנה מטרה	Revenue
מחלקה חיובית	ביקור שהסתיים ברכישה
מחלקה שלילית	ביקור שלא הסתיים ברכישה
שיעור רכישה	15.5%
שיעור ללא רכישה	84.5%

3.1 קבוצות המאפיינים

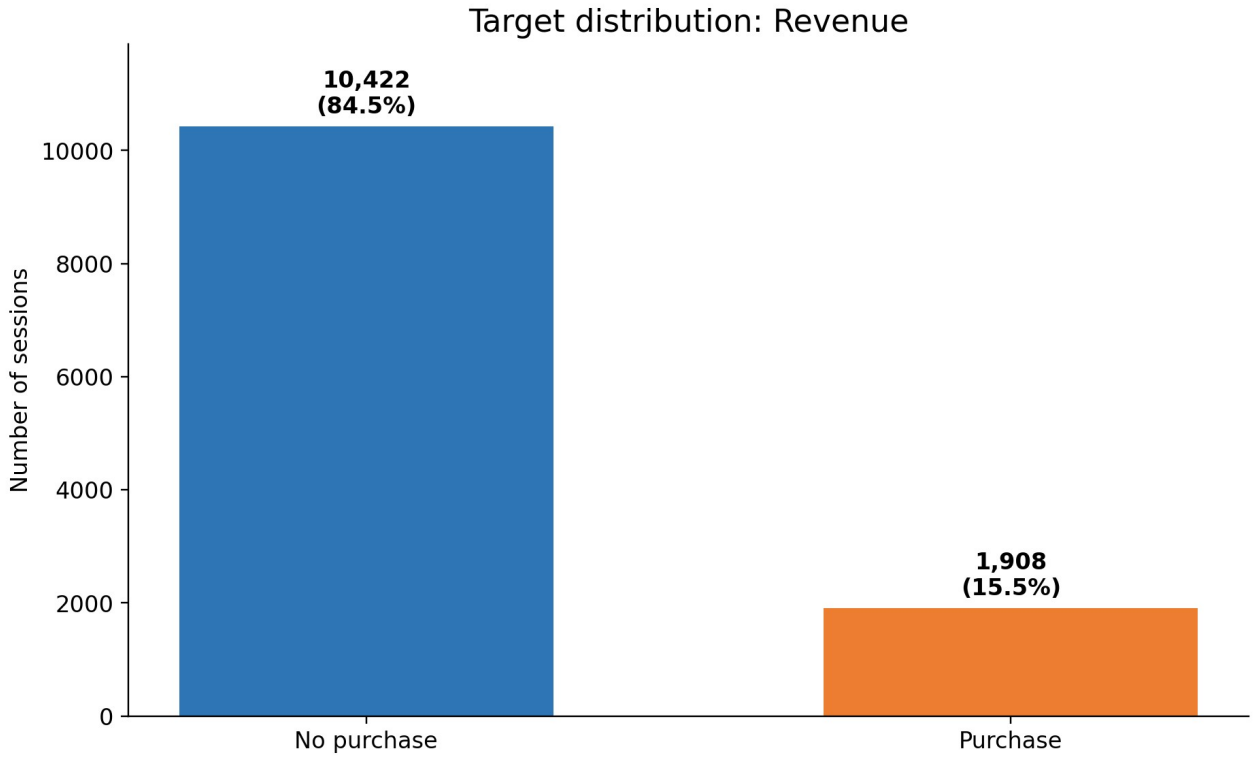
- פעילות בדפים מנהליים - Administrative ו-Administrative_Duration.
- פעילות בדפי מידע - Informational ו-Informational_Duration.
- פעילות בדפי מוצרים - ProductRelated ו-ProductRelated_Duration.
- מדדי התנהגות - BounceRates, ExitRates, PageValues ו-SpecialDay.
- מידע טכני ושיווקי - OperatingSystems, Browser, Region ו-TrafficType.
- זמן וסוג משתמש - Month, VisitorType ו-Weekend.

> נקודה מתודולוגית: חלק מהעמודות מקודדות במספרים אך הן קטגוריאליות. לדוגמה, Browser=4 אינו ערך כמותי גדול יותר מ-Browser=2. לכן עמודות אלה טופלו באמצעות One-Hot Encoding.

4. חקירת הנתונים - Exploratory Data Analysis

לפני אימון המודלים בוצעה חקירה מפורטת של המאגר. המטרה הייתה להבין את חוסר האיזון, לזהות הבדלים התנהגותיים בין רוכשים ללא-רוכשים, לבדוק עונתיות וקשרים בין מאפיינים, ולגבש השערות שיסבירו בהמשך את תוצאות המודלים.

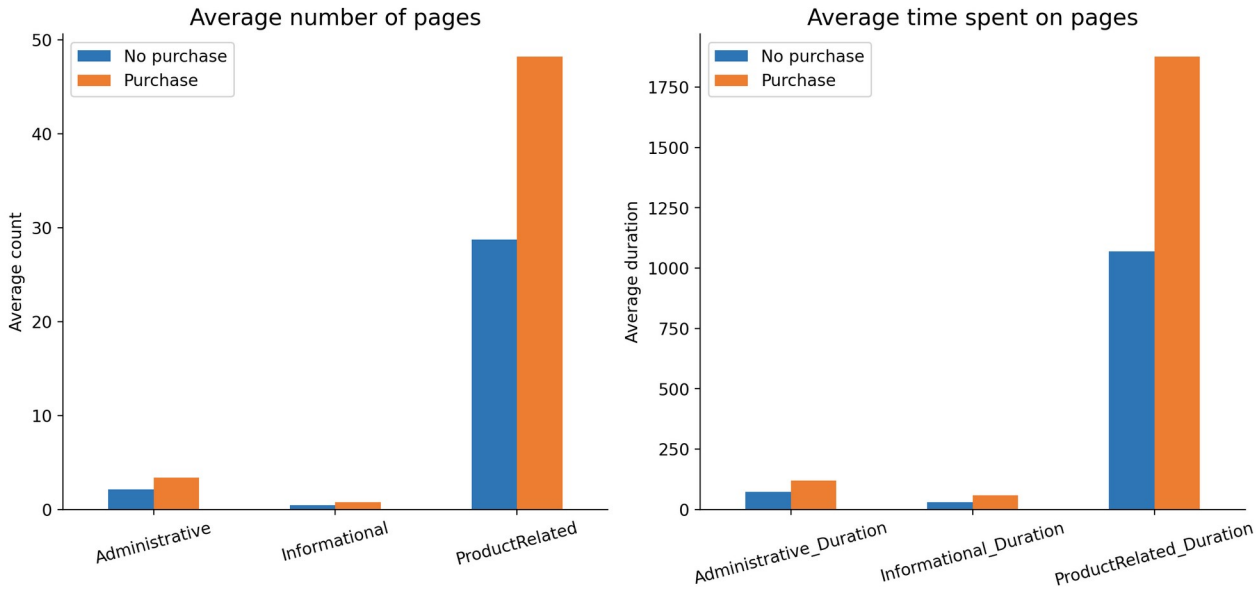
4.1 התפלגות משתנה המטרה



איור 1: התפלגות **Revenue** במאגר

> מה ניתן להסיק: קיימת אי-סימטריה ברורה: 10,422 ביקורים לא הסתיימו ברכישה ורק 1,908 הסתיימו ברכישה. מודל שמנבא תמיד "ללא רכישה" יקבל Accuracy של כ-84.5%, ולכן Accuracy לבדו אינו מדד מספק.

4.2 הבדלים ברמת המעורבות באתר



איור 2: השוואת ממוצע מספר הדפים וזמן השהייה לפי תוצאת הביקור

מה ניתן להסיק: ביקורים שהסתיימו ברכישה כללו בממוצע יותר דפים מכל הסוגים וזמן שהייה ארוך יותר. הפער בולט במיוחד בדפי מוצרים: רוכשים צפו בכ-48.2 דפי מוצרים בממוצע לעומת כ-28.7 אצל לא-רוכשים, ושהו בהם כ-1,876 שניות לעומת כ-1,070 שניות.

טבלה 2: ממוצעי מעורבות מרכזיים לפי **Revenue**

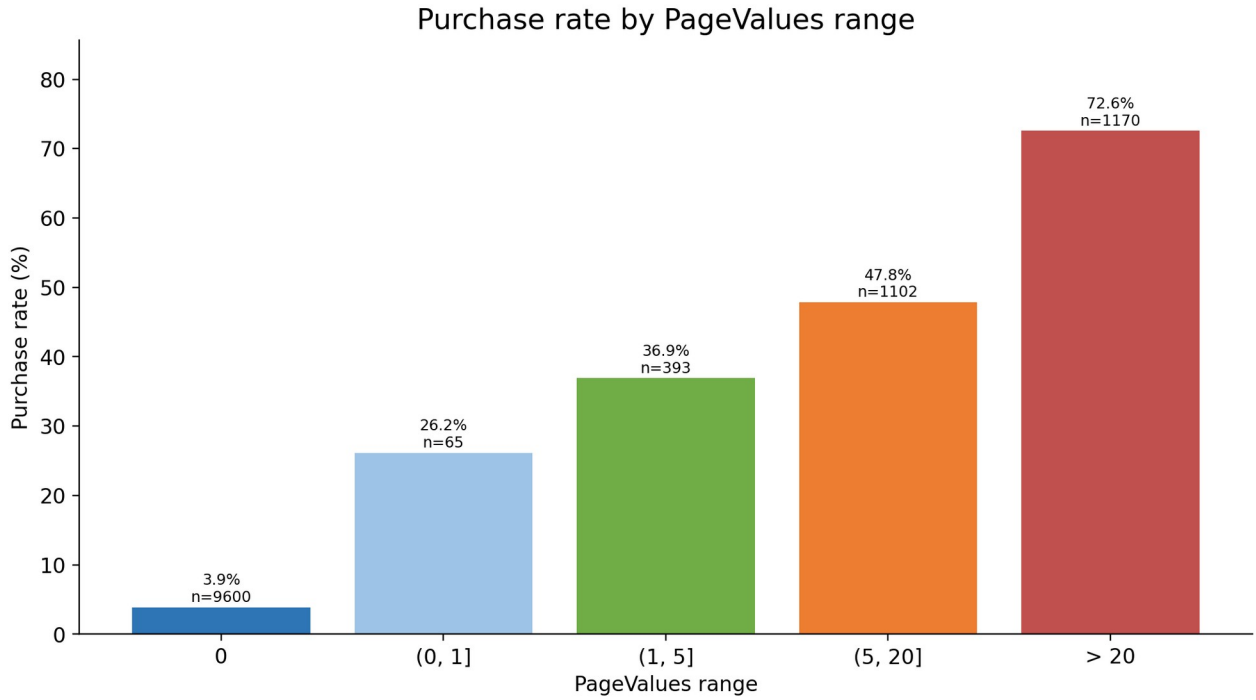
מאפיין	ללא רכישה	רכישה	פרשנות
Administrative	2.12	3.39	רוכשים מבקרים ביותר דפים מנהליים
Informational	0.45	0.79	רוכשים צורכים יותר מידע
ProductRelated	28.71	48.21	מעורבות גבוהה יותר בדפי מוצרים
ProductRelated_Duration	1,069.99	1,876.21	שהייה ארוכה יותר לפני רכישה

4.3 **PageValues** - המאפיין הבולט ביותר



איור 3: התפלגות **PageValues** לפי תוצאת הביקור

מה ניתן להסיק: PageValues גבוה בהרבה אצל ביקורים שהסתיימו ברכישה. הממוצע בקרב רוכשים הוא כ-27.26 לעומת כ-1.98 בקרב לא-רוכשים. הפער הגדול מסביר מדוע המאפיין קיבל חשיבות גבוהה במיוחד ב-Random Forest. עם זאת, ההתפלגות אינה מפרידה באופן מושלם ולכן אין להסתמך עליו לבדו.

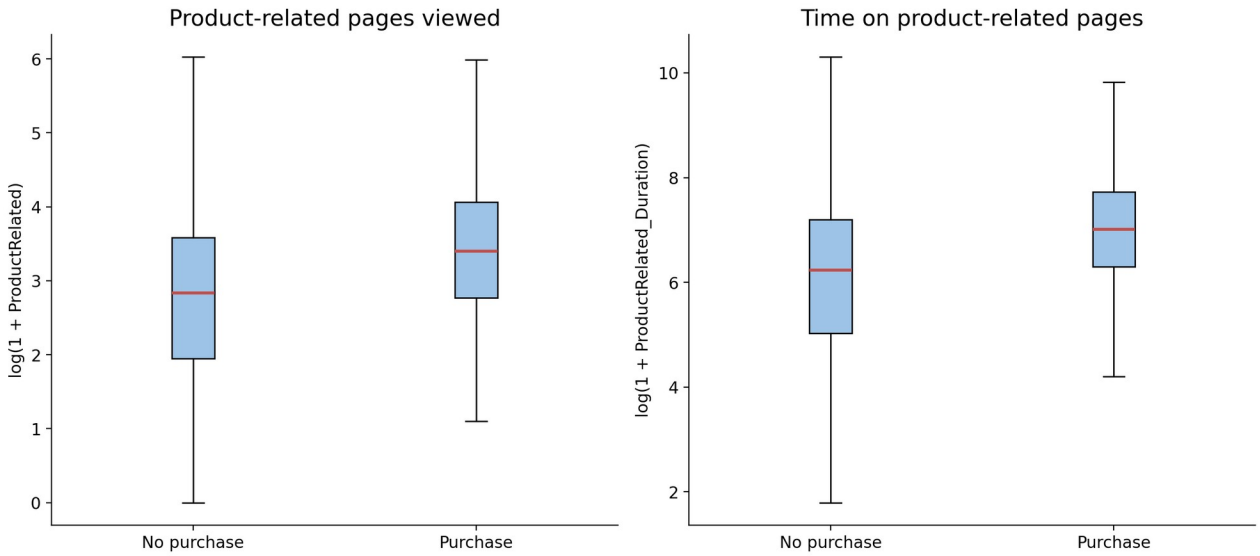


איור 4: שיעור הרכישה לפי טווחי **PageValues**

מה ניתן להסיק: ככל ש-PageValues עולה, שיעור הרכישה גדל בצורה חדה. זהו קשר חזק מבחינה ניבויית, אך

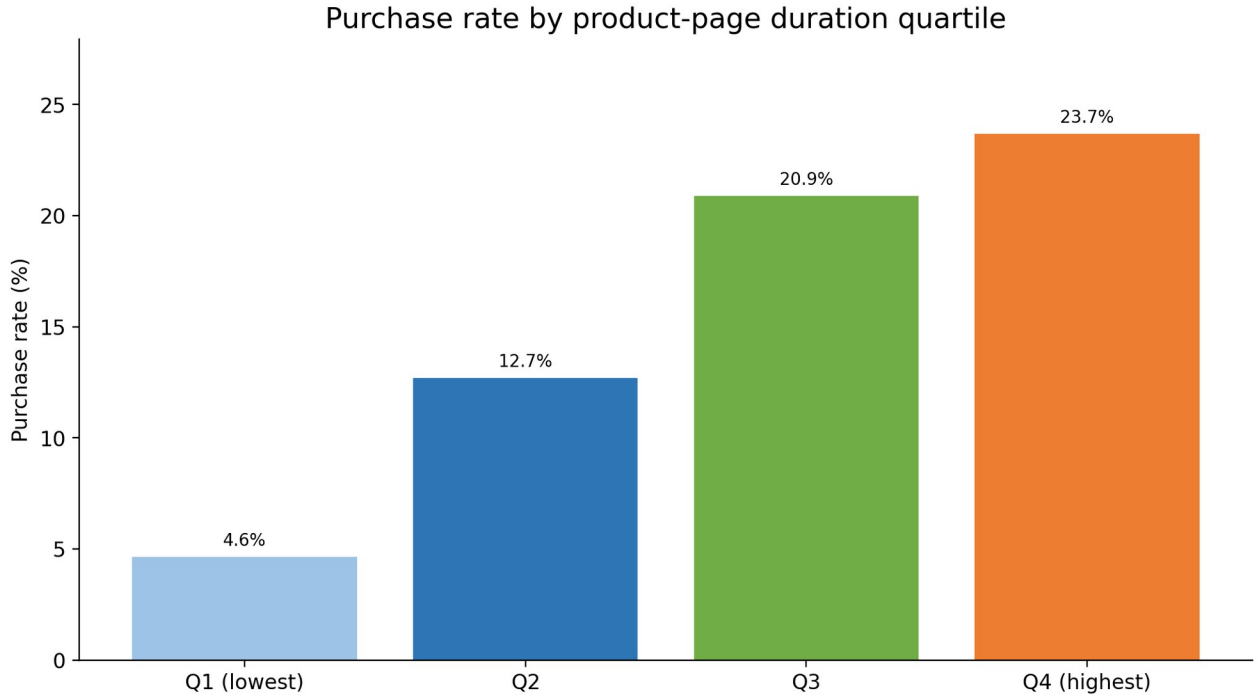
עדיין מדובר בקשר תיאורי ולא בהוכחת סיבתיות.

4.4 פעילות בדפי מוצרים



איור 5: מספר דפי מוצרים וזמן השהייה לפי **Revenue**

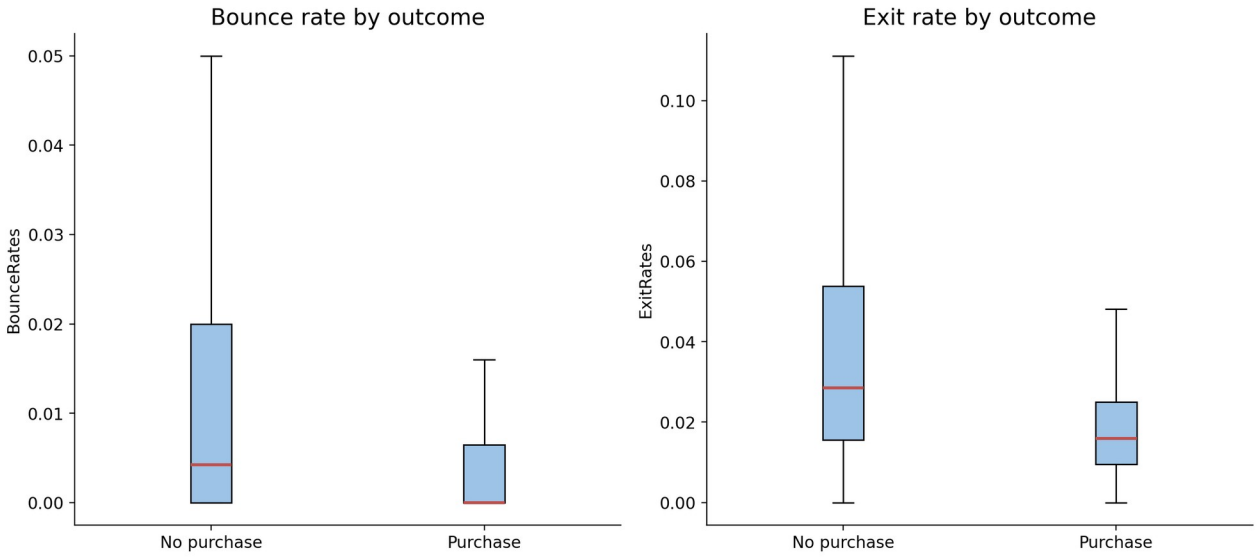
מה ניתן להסיק: גם לאחר שימוש בסולם לוגריתמי ניתן לראות שההתפלגות של הרוכשים נוטה לערכים גבוהים יותר. המשמעות היא שמעורבות עמוקה יותר בקטלוג המוצרים קשורה לסיכוי רכישה גבוה יותר.



איור 6: שיעור הרכישה לפי רבעוני זמן השהייה בדפי מוצרים

מה ניתן להסיק: שיעור הרכישה גדל בין הרבעונים, ובעיקר בקבוצת המשתמשים ששהו את הזמן הרב ביותר בדפי מוצרים. התוצאה תומכת בכך שמשך השהייה הוא אות שימושי, אך ייתכן גם שהוא מייצג שלבים שונים במסע הלקוח.

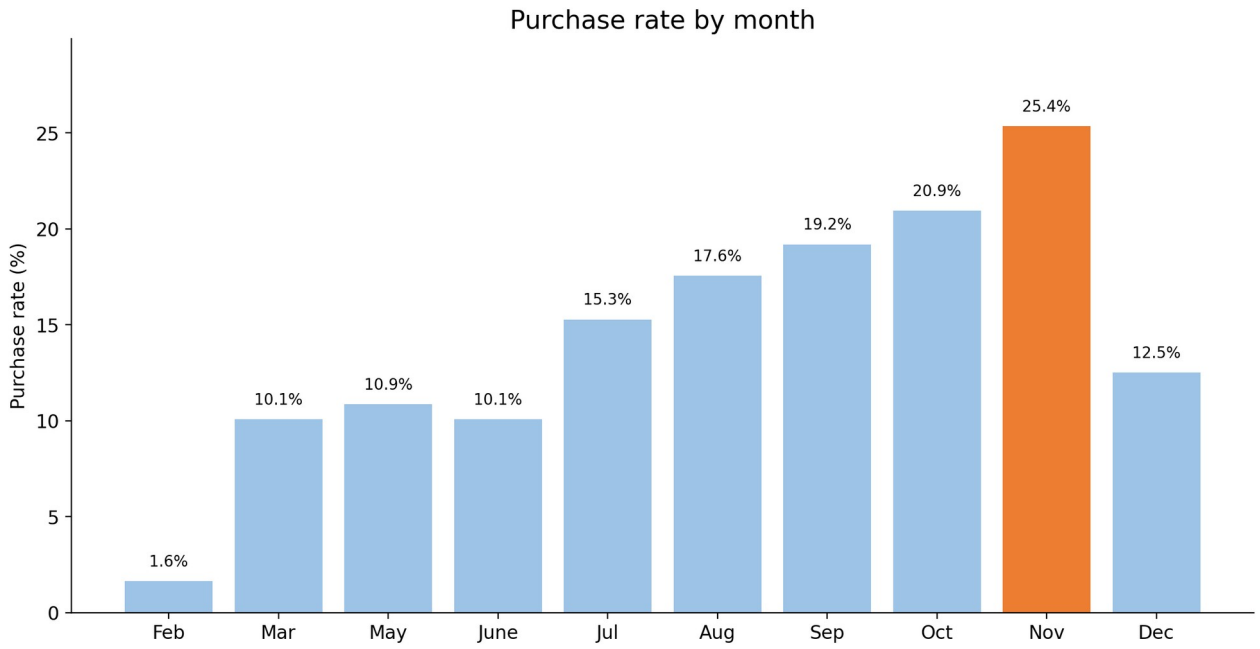
4.5 BounceRates ו-ExitRates



איור 7: שיעורי נטישה ויציאה לפי תוצאת הביקור

מה ניתן להסיק: רוכשים מאופיינים בשיעורי Bounce ו-Exit נמוכים יותר. הממוצע של ExitRates הוא כ-0.0196 אצל רוכשים לעומת כ-0.0474 אצל לא-רוכשים. הדבר מתאים לאינטואיציה: משתמש שעוזב במהירות או יוצא בתדירות גבוהה נמצא בסבירות נמוכה יותר להשלים עסקה.

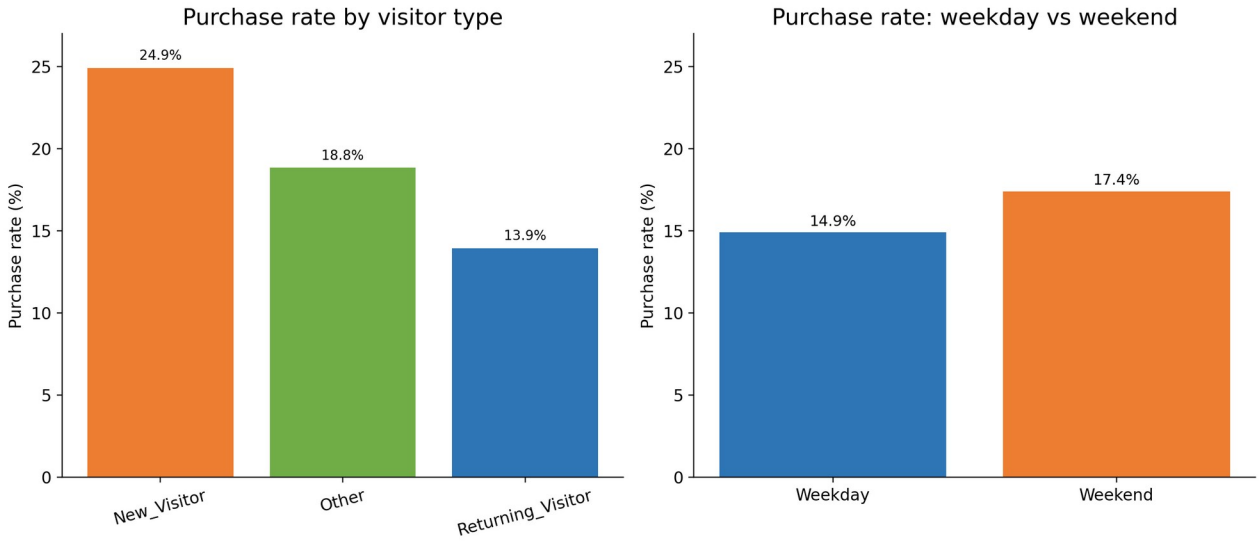
4.6 עונתיות ושיעור רכישה לפי חודש



איור 8: שיעור רכישה לפי חודש

מה ניתן להסיק: קיימת עונתיות ברורה. נובמבר מוביל עם שיעור רכישה של כ-25.4%, אחריו אוקטובר וספטמבר. פברואר נמוך במיוחד. Month_Nov הופיע גם בין מאפייני החשיבות הבולטים של Random Forest. יש להיזהר מפרשנות יתר משום שמספר הדוגמאות שונה בין החודשים.

4.7 סוג מבקר וסוף שבוע

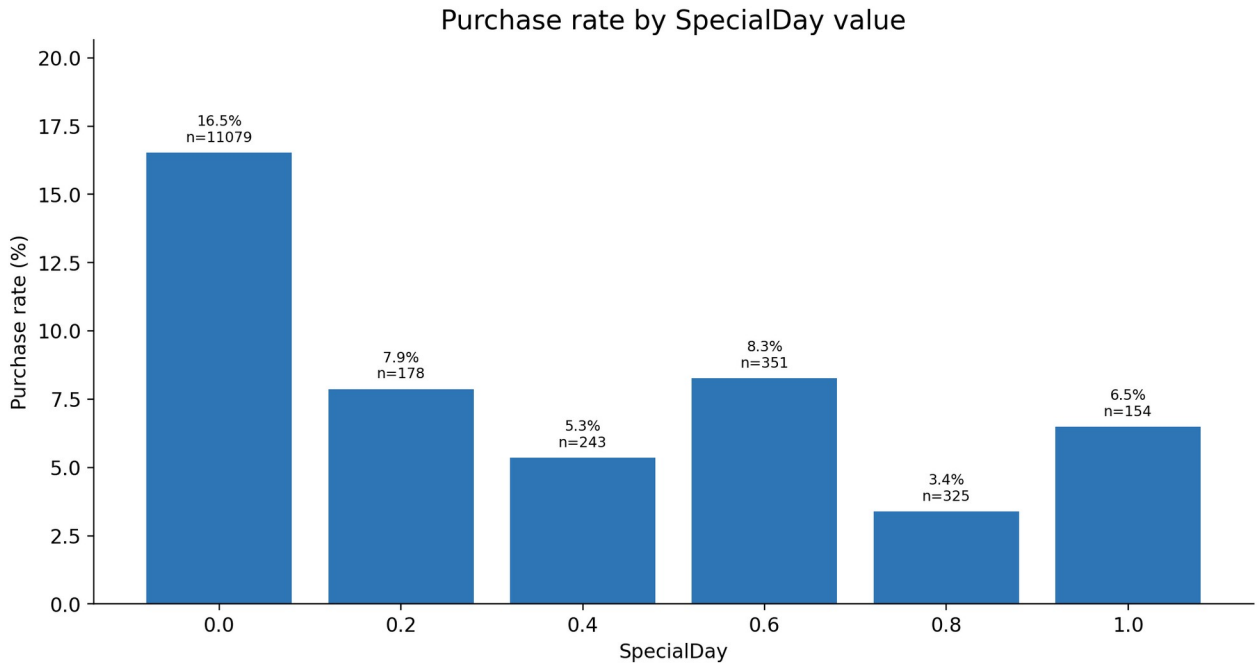


איור 9: שיעור רכישה לפי **VisitorType** ולפי **Weekend**

מה ניתן להסיק: במאגר זה New_Visitor מציג שיעור רכישה גבוה יותר מ-Returning_Visitor, תוצאה שאינה בהכרח צפויה ודורשת זהירות בפרשנות. ייתכן שקבוצות המבקרים מגיעות דרך ערוצי שיווק שונים. בסופי שבוע

שיעור הרכישה גבוה מעט יותר, אך הפער קטן יחסית לעומת השפעת PageValues או החודש.

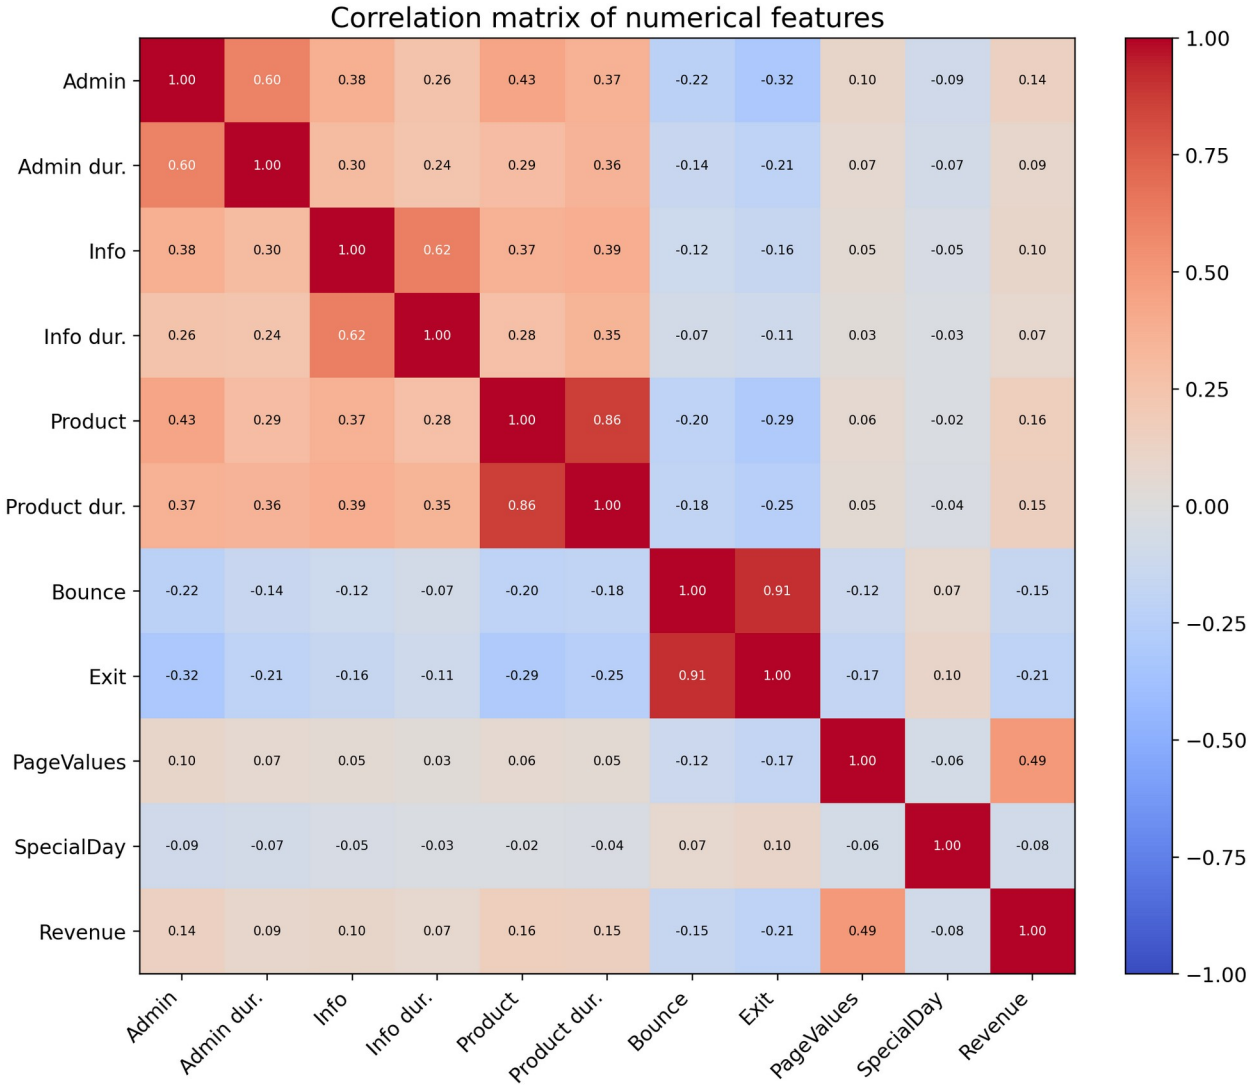
4.8 קרבה ליום מיוחד



איור 10: שיעור רכישה לפי **SpecialDay**

מה ניתן להסיק: דווקא ביקורים שאינם סמוכים ליום מיוחד מציגים שיעור רכישה גבוה יותר. ייתכן שמשתמשים מבקרים סמוך לחגים לצורך השוואה או חיפוש מוקדם, או שקיימים הבדלים בהרכב הדוגמאות. מאחר שהקבוצות אינן שוות בגודלן, אין להסיק קשר סיבתי.

4.9 קשרים בין המאפיינים המספריים



איור 11: מטריצת קורלציה של המאפיינים המספריים

מה ניתן להסיק: נראים קשרים חזקים בין מספר הדפים לבין משך השהייה באותו סוג דף, וכן קשר בין BounceRates ל-ExitRates. PageValues מציג את הקורלציה החיובית הבולטת ביותר עם Revenue. הקורלציות בין מאפיינים קשורים מספקות הצדקה לבדוק PCA, אך קורלציה לינארית אינה מתארת את כל היחסים האפשריים.

4.10 מסקנות חקירת הנתונים

- המאגר אינו מאוזן ולכן יש להעריך את מחלקת הרכישה באופן מפורש.
- PageValues הוא אות חזק במיוחד, אך אינו מפריד לבדו בין המחלקות.
- רוכשים מציגים מעורבות גבוהה יותר בדפי מוצרים ובדפי מידע.
- BounceRates ו-ExitRates נמוכים יותר אצל רוכשים.
- קיימת עונתיות משמעותית, במיוחד בחודשים ספטמבר-נובמבר.
- חלק מהמאפיינים המספריים קשורים זה לזה, ולכן נבדקה גם הפחתת ממדים.

הפרויקט פותח ב-Python בסביבת VS Code ו-WSL/Linux, תוך שימוש ב-Git וב-GitHub לניהול גרסאות.
הספריות המרכזיות היו pandas, NumPy, scikit-learn, imbalanced-learn ו-Matplotlib.

```
/Online_Shoppers_Purchase_Prediction_Project
├── data/online_shoppers_intention.csv
├── scripts/01_eda.py
├── scripts/02_train_models.py
├── scripts/03_feature_importance.py
├── scripts/04_imbalance_analysis.py
├── scripts/05_random_forest_improvement.py
├── scripts/06_course_extensions.py
├── scripts/07_pca_knn_experiment.py
├── scripts/08_tuned_pca_smote_knn.py
├── /results
├── report/final_report_hebrew.md
├── README.md
└── requirements.txt
```

- 01_**eda.py** - חקירת הנתונים, טבלאות וגרפים.
- 02_**train_models.py** - השוואת חמישה מודלים מרכזיים.
- 03_**feature_importance.py** - חשיבות מאפיינים עבור Random Forest.
- 04_**imbalance_analysis.py** - השוואת גרסאות מאוזנות ולא מאוזנות.
- 05_Grid Search **random_forest_improvement.py -** וכיוונון סף החלטה.
- 06_AdaBoost **course_extensions.py -** ו-PCA לשני ממדים.
- 07_**pca_knn_experiment.py** - השוואת KNN, PCA, SMOTE והשילוב ביניהם.
- 08_Grid Search **tuned_pca_smote_knn.py -** לצינור PCA-SMOTE-KNN.

6.1 חלוקת הנתונים

בניסוי המרכזי הנתונים חולקו ל-80% אימון ו-20% בדיקה באמצעות stratify=y ו-random_state=42. Stratification שמרה על שיעור הרכישות בשתי הקבוצות.

```
)train_test_split
    ,X, y, test_size=0.20
random_state=42, stratify=y
                        (
```

6.2 Scaling ו-One-Hot Encoding

המאפיינים המספריים עברו StandardScaler. הפעולה חשובה במיוחד עבור Logistic Regression, SVM, KNN ו-PCA. המאפיינים הקטגוריאליים עברו OneHotEncoder עם handle_unknown="ignore".

6.3 Pipeline

העיבוד והמודל שולבו ב-Pipeline. בניסויי SMOTE נעשה שימוש ב-imblearn.pipeline.Pipeline, כדי שהדוגמאות הסינתטיות ייווצרו רק בתוך קבוצת האימון של כל קיפול ולא על נתוני הבדיקה.

> מניעת דליפת מידע: אסור לבצע scaling, PCA או SMOTE על כל המאגר לפני החלוקה. אחרת נתוני הבדיקה משפיעים בעקיפין על האימון והערכת הביצועים נעשית אופטימית מדי.

7.1 Logistic Regression

מודל לינארי לסיווג בינארי. מהיר וברור, אך עלול להתקשות בקשרים לא-לינאריים. בפרויקט הופעל עם "class_weight="balanced.

7.2 K-Nearest Neighbors

מסווג דוגמה לפי השכנים הקרובים. רגיש לסקאלה, לחוסר איזון ולממדיות גבוהה. במודל הבסיסי נעשה שימוש בחמישה שכנים.

7.3 Decision Tree

לומד סדרת כללי פיצול ויכול לזהות קשרים לא-לינאריים. החיסרון המרכזי הוא חוסר יציבות וסיכון ל-overfitting.

7.4 Random Forest

אוסף של עצים המאומנים על דגימות ותתי-קבוצות מאפיינים. יציב מעץ יחיד, מתאים לאינטראקציות ומאפשר חישוב Feature Importance.

7.5 Linear SVM

מחפש מפריד לינארי בעל שוליים רחבים. מתאים לממד גבוה לאחר scaling, אך אינו מייצג קשרים לא-לינאריים מורכבים.

7.6 AdaBoost

מאמן רצף של מודלים חלשים ומתמקד בדוגמאות שבהן בוצעו טעויות. עשוי להיות רגיש לרעש ולדוגמאות חריגות.

7.7 PCA

שיטה לא-מפוקחת להפחתת ממדים. היא שומרת כיוונים בעלי שונות גבוהה ואינה משתמשת בתווית Revenue.

7.8 SMOTE

שיטה ליצירת דוגמאות סינתטיות למחלקת המיעוט בין דוגמאות שכנות. מטרתה לשפר את יכולת המודל ללמוד את מחלקת הרכישה.

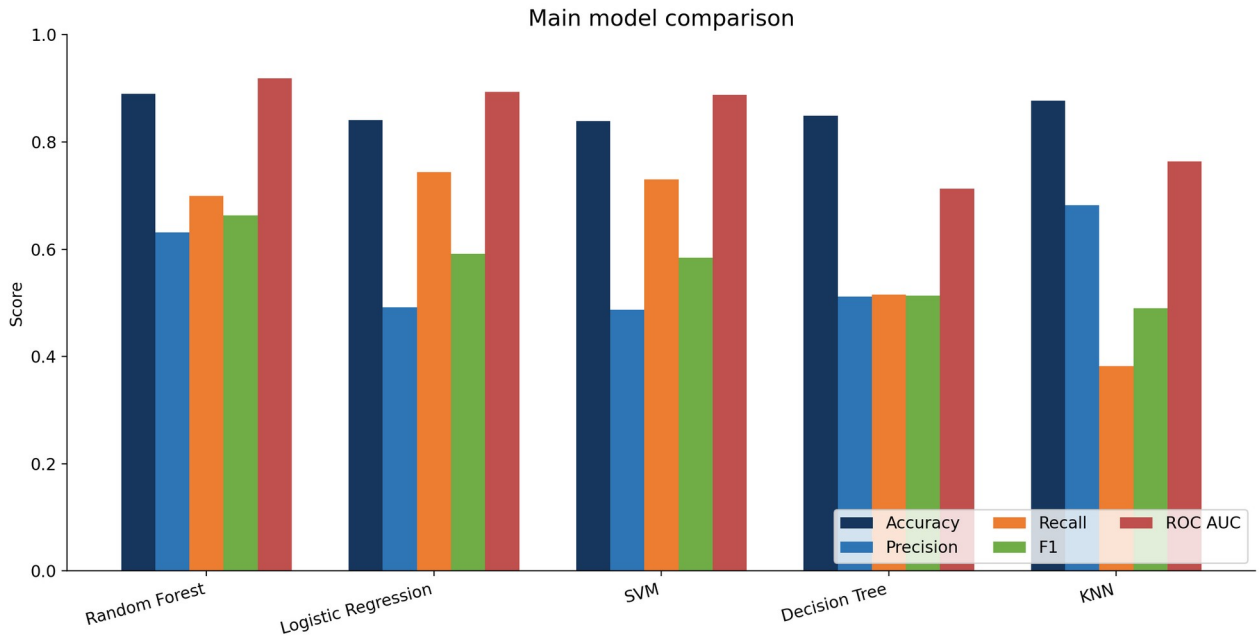
טבלה 3: מדדי ההערכה ששימשו בפרויקט

מדד	משמעות בפרויקט
Accuracy	שיעור התחזיות הנכונות מכלל הדוגמאות; עלול להטעות בגלל מחלקת הרוב.
Precision	מתוך התחזיות לרכישה - כמה היו רכישות אמיתיות.
Recall	מתוך כל הרכישות האמיתיות - כמה המודל זיהה.
F1	ממוצע הרמוני של Precision ו-Recall; מדד מרכזי בפרויקט.
ROC AUC	יכולת דירוג והפרדה בין המחלקות לאורך ספים שונים.

הבחירה במודל לא התבססה על מדד יחיד. Random Forest נבחר משום שהשיג את ה-F1 ואת ה-ROC AUC הגבוהים ביותר, ולא משום שהיה הטוב ביותר בכל מדד בנפרד.

טבלה 4: תוצאות השוואת המודלים

מודל	Accuracy	Precision	Recall	F1	ROC AUC
Random Forest	0.8901	0.6312	0.6990	0.6634	0.9191
Logistic Regression	0.8410	0.4913	0.7435	0.5917	0.8932
SVM	0.8390	0.4869	0.7304	0.5843	0.8879
Decision Tree	0.8487	0.5117	0.5157	0.5137	0.7127
KNN	0.8767	0.6822	0.3822	0.4899	0.7633

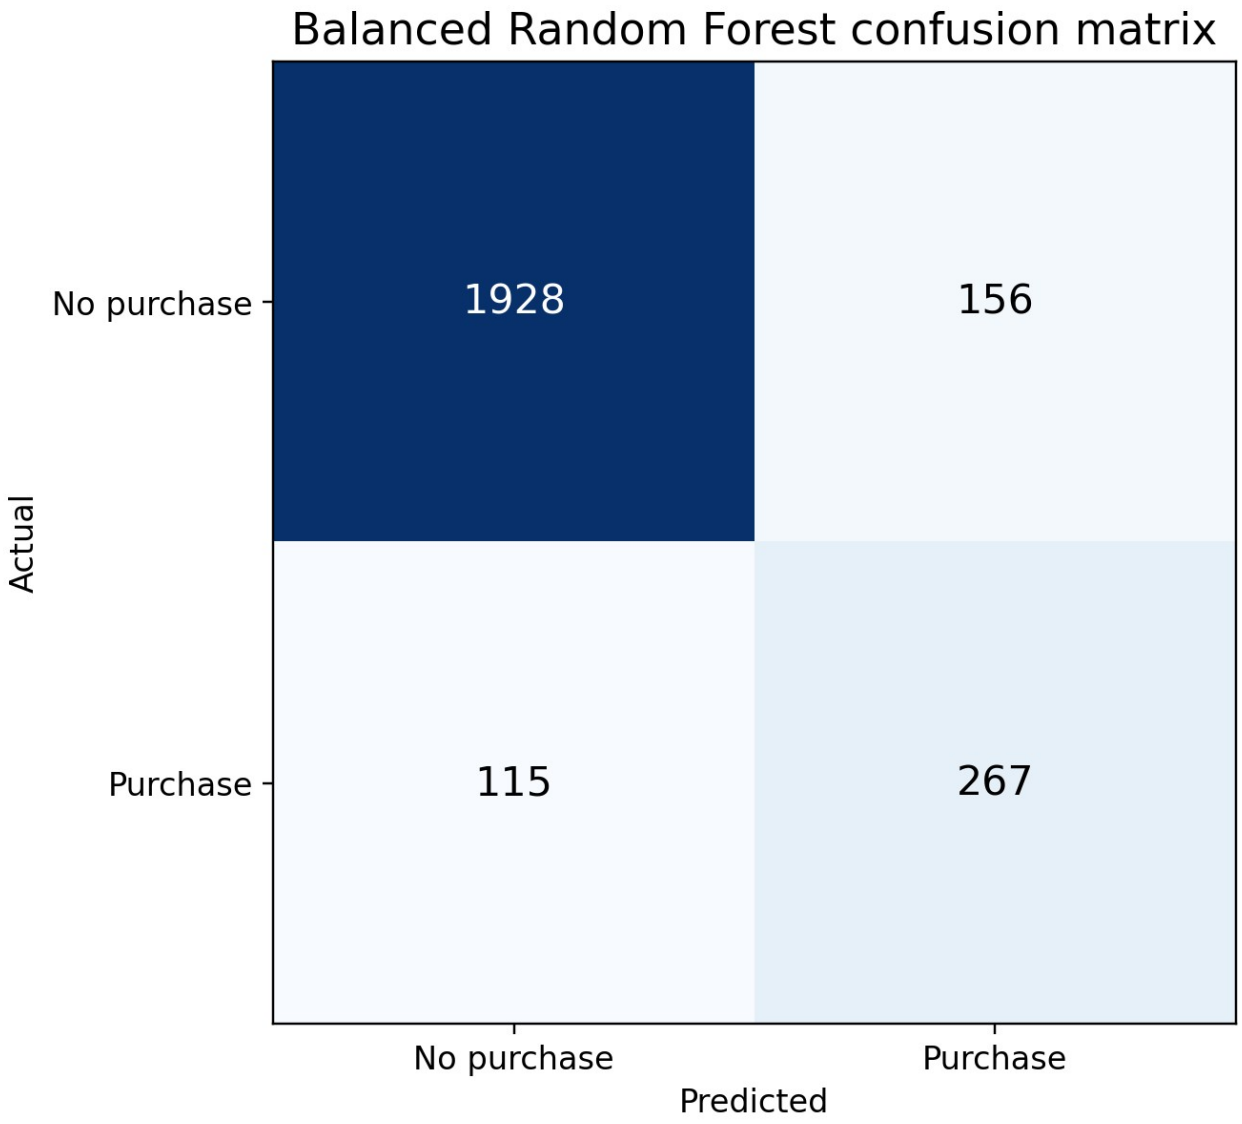


איור 12: השוואת המדדים של חמשת המודלים

מה ניתן להסיק: Random Forest משיג את F1 ואת ROC AUC הגבוהים ביותר. Logistic Regression ו-SVM משיגים Recall גבוה יותר, אך Precision נמוך יותר. KNN מדויק יחסית כאשר הוא חוזה רכישה, אך מפספס רכישות רבות.

9.1 המודל המוביל - **Random Forest**

- Accuracy: 0.8901
- Precision: 0.6312
- Recall: 0.6990
- F1: 0.6634
- ROC AUC: 0.9191



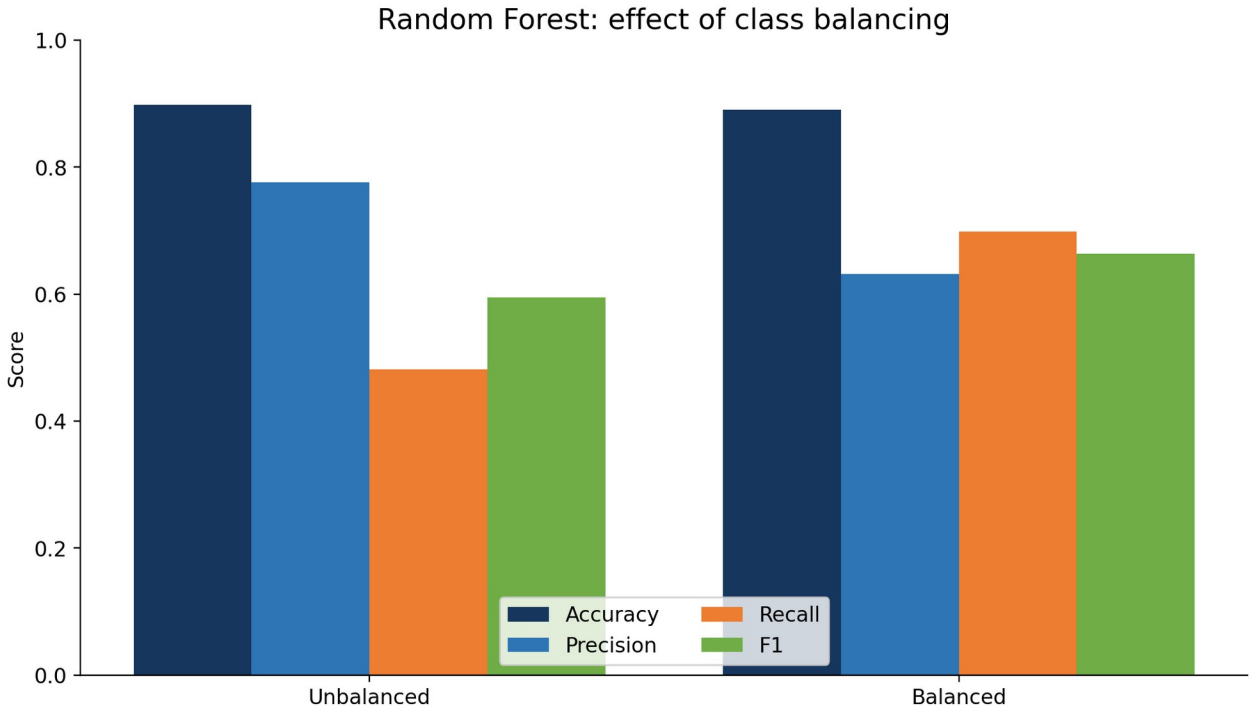
איור 13: מטריצת הבלבול של **Random Forest** המאוזן

מה ניתן להסיק: המודל זיהה 267 מתוך 382 רכישות בקבוצת הבדיקה. הוא פספס 115 רכישות ויצר 156 תחזיות רכישה שגויות. המטריצה ממחישה את האיזון בין זיהוי מחלקת המיעוט לבין מספר ה-False Positives.

Dummy Classifier החוזה תמיד את מחלקת הרוב השיג Accuracy של 0.8451, אך Precision, Recall ו-F1 של אפס עבור רכישות. תוצאה זו מראה בצורה ישירה מדוע Accuracy אינו מספיק.

טבלה 5: השפעת איזון המחלקות על **Random Forest**

גרסה	Accuracy	Precision	Recall	F1
ללא איזון	0.8982	0.7764	0.4817	0.5945
עם class_weight="balanced"	0.8901	0.6312	0.6990	0.6634



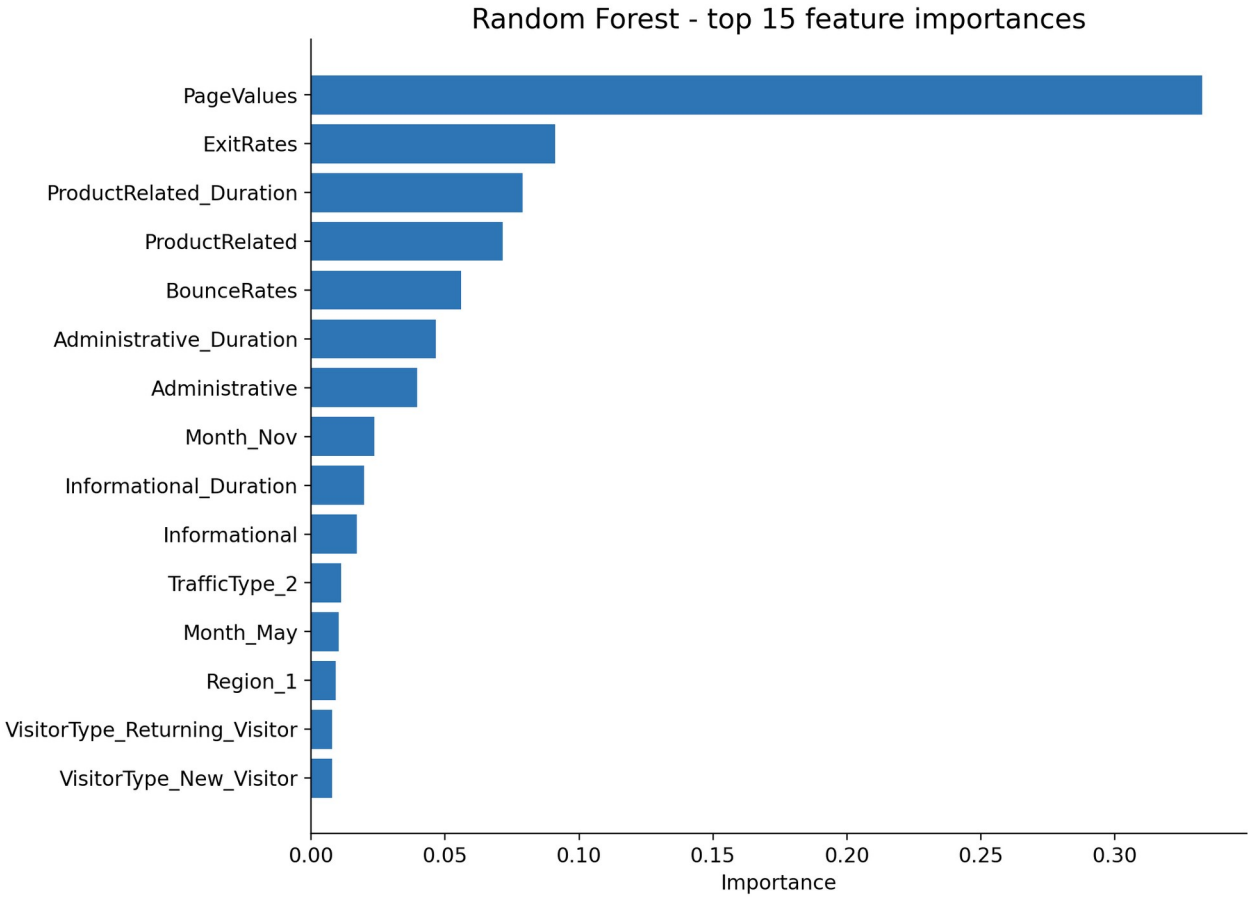
איור 14: **Random Forest** ללא איזון לעומת **Random Forest** מאוזן

מה ניתן להסיק: האיזון הוריד מעט את Accuracy ואת Precision, אך העלה את Recall מ-0.4817 ל-0.6990 ואת F1 מ-0.5945 ל-0.6634. עבור מטרת הפרויקט זהו שיפור חשוב, משום שהמודל מפספס פחות רוכשים.

מסקנה: איזון מחלקות אינו משפר כל מדד ואינו מבטיח שיפור בכל מודל. ב-Decision Tree הוא אף לא שיפר את F1. לכן יש לבדוק את ההשפעה אמפירית ולא להניח מראש שאיזון תמיד עדיף.

טבלה 6: עשרת המאפיינים החשובים ביותר ב-**Random Forest**

דירוג	מאפיין	חשיבות
1	PageValues	0.3326
2	ExitRates	0.0911
3	ProductRelated_Duration	0.0789
4	ProductRelated	0.0715
5	BounceRates	0.0561
6	Administrative_Duration	0.0465
7	Administrative	0.0395
8	Month_Nov	0.0235
9	Informational_Duration	0.0199
10	Informational	0.0170



איור 15: 15 המאפיינים החשובים ביותר לפי **Random Forest**

> מה ניתן להסיק: PageValues מוביל בפער גדול. אחריו נמצאים ExitRates, משך ומספר דפי המוצרים, BounceRates ופעילות בדפים מנהליים. התוצאה עקבית עם ממצאי ה-EDA.

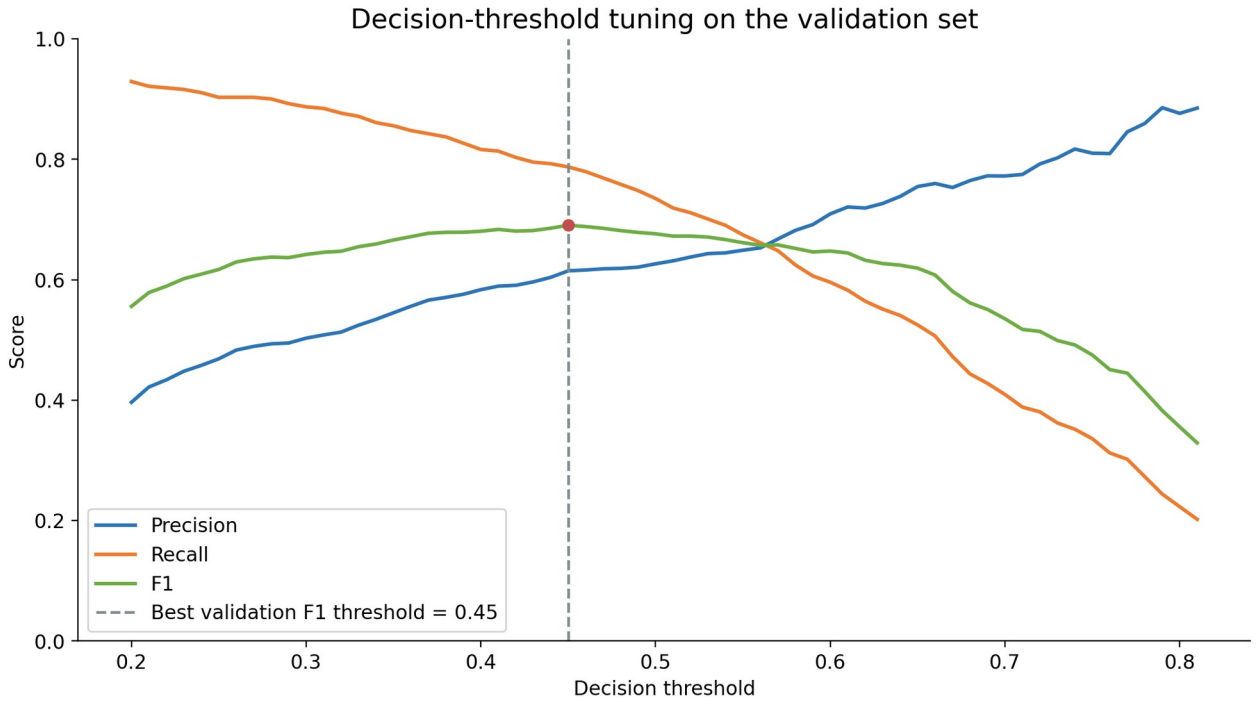
Feature Importance מתאר כיצד המודל השתמש במאפיינים לצורך החיזוי. הוא אינו מוכיח קשר סיבתי. בנוסף, כאשר מאפיינים קשורים זה לזה, החשיבות יכולה להתחלק ביניהם.

12. ניסיון לשיפור **Random Forest**

בניסוי זה הנתונים חולקו ל-training, validation ו-test. בוצע Grid Search לפי F1 ולאחר מכן נבדקו ספי החלטה שונים על קבוצת ה-validation. בגלל חלוקה זו, המודל בניסוי השיפור אומן על פחות דוגמאות מהמודל בהשוואה הראשית ולכן תוצאות ה-baseline שונות מעט.

טבלה 7: תוצאות ניסוי שיפור **Random Forest**

ROC AUC	F1	Recall	Precision	Accuracy	גרסה
0.9149	0.6508	0.6806	0.6235	0.8869	Baseline Random Forest
0.9139	0.6460	0.6806	0.6147	0.8844	Tuned Random Forest - threshold 0.5
0.9139	0.6485	0.7173	0.5918	0.8796	Tuned Random Forest - threshold 0.45



איור 16: **Precision, Recall** ו-**F1** לאורך ספי החלטה שונים

מה ניתן להסיק: כאשר מורידים את הסף, Recall עולה ו-Precision יורד. הסף הטוב ביותר על validation אינו מבטיח את התוצאה הטובה ביותר על test. בניסוי הסופי סף 0.45 העלה Recall ל-0.7173, אך לא עבר את F1 של ה-baseline.

משמעות עסקית: בחירת סף יכולה להיות תלויה בעלות הטעות. אם פספוס רוכש יקר מאוד, אפשר לבחור סף נמוך יותר. אם פנייה שיווקית שגויה יקרה או פוגעת בחוויית המשתמש, ייתכן שעדיף סף גבוה יותר.

13. **AdaBoost** ו-**PCA** לצורך המחשה

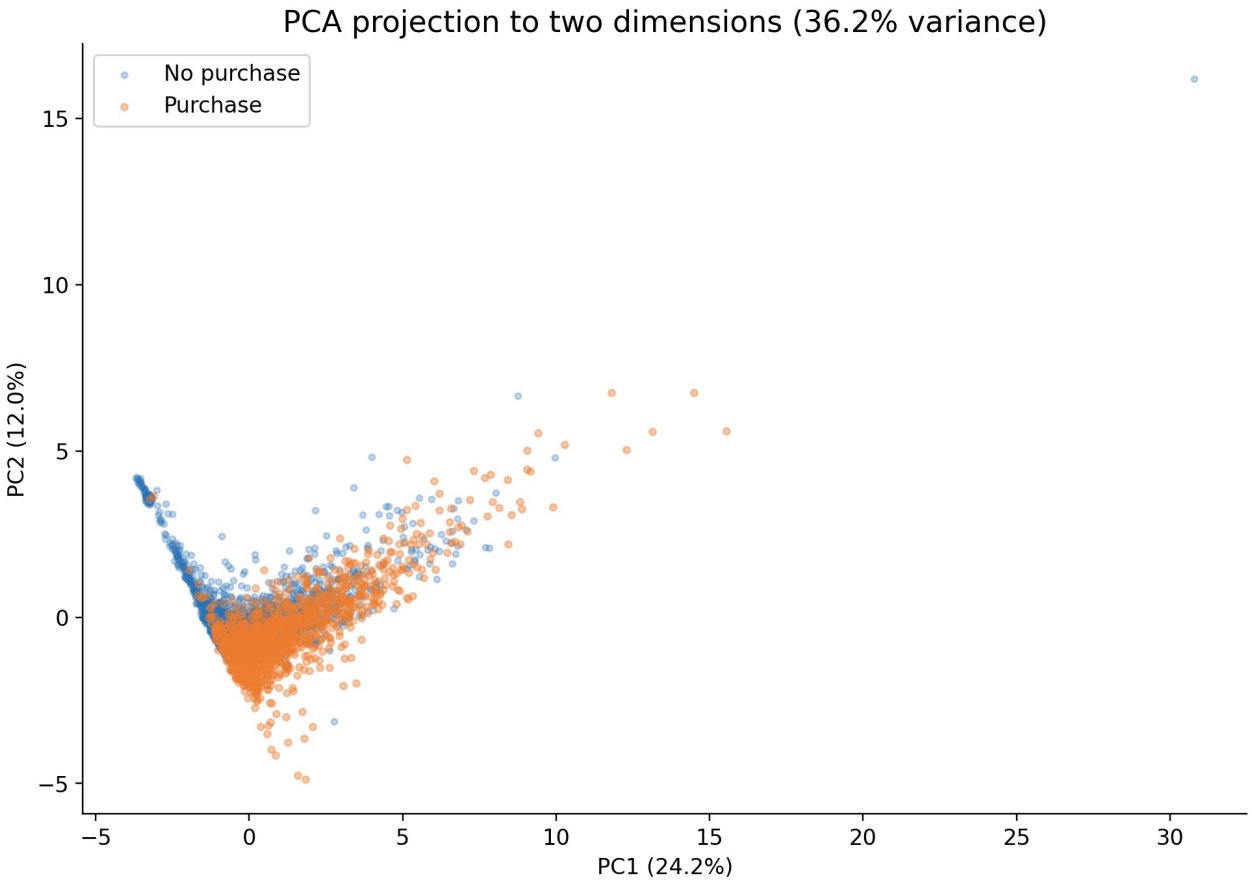
13.1 **AdaBoost**

טבלה 8: תוצאות **AdaBoost**

ROC AUC	F1	Recall	Precision	Accuracy
0.9148	0.6233	0.5890	0.6618	0.8897

AdaBoost הציג ביצועים טובים, אך F1 נמוך יותר מ-Random Forest המאוזן בגלל Recall נמוך יותר. הניסוי הראה שמודל Ensemble נוסף אינו בהכרח עובר את Random Forest.

13.2 PCA לשני ממדים



איור 17: הקרנת הנתונים לשני רכיבי **PCA**

> מה ניתן להסיק: שני הרכיבים הראשונים מסבירים רק כ-36% מהשונות וקיימת חפיפה נרחבת בין המחלקות. לכן הגרף מתאים להמחשה אך אינו מעיד שניתן לבצע סיווג טוב בשני ממדים בלבד.

PCA אינה משתמשת בתווית Revenue. מטרתה לשמור שונות כללית, לא ליצור הפרדה מיטבית בין רכישות ללא-רכישות.

14. ניסוי PCA, SMOTE ו-KNN

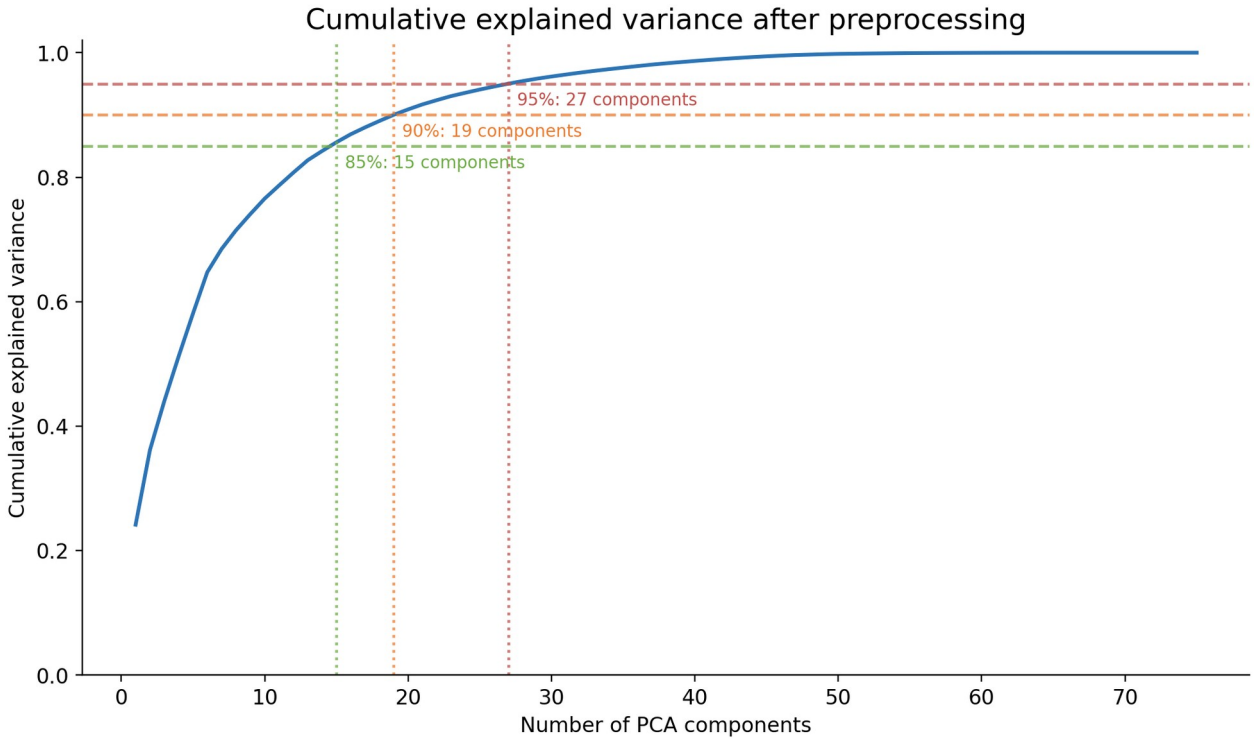
14.1 מטרת הניסוי

KNN הבסיסי השיג Precision של 0.6822 אך Recall של 0.3822. נבדק האם המקור לכך הוא הממד הגבוה שנוצר לאחר One-Hot Encoding והעובדה שמחלקת הרכישה קטנה.

14.2 בחירת מספר רכיבי PCA

PCA הוגדר עם n_components=0.90, כלומר בחירת המספר המינימלי של רכיבים המסביר לפחות 90% מהשונות בנתוני האימון.

```
PCA(n_components=0.90, svd_solver="full")
```



איור 18: שונות מצטברת לפי מספר רכיבי **PCA**

מה ניתן להסיק: לאחר preprocessing התקבלו 75 מאפיינים. 15 רכיבים שמרו כ-85% מהשונות, 20 רכיבים שמרו כ-90.8%, ו-28 רכיבים שמרו כ-95%. בניסוי המרכזי נבחר יעד של 90%, המאזן בין צמצום משמעותי לבין שמירת רוב המידע.

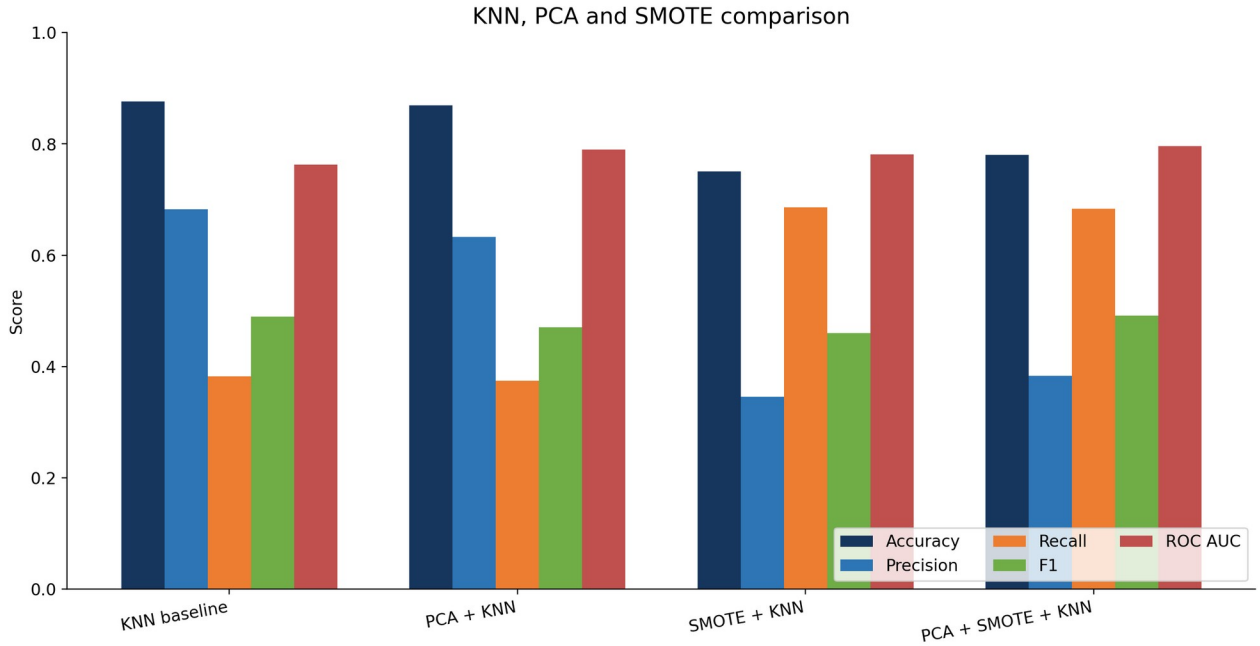
14.3 מבנה הניסוי

```
Preprocessing → PCA → SMOTE → KNN
```

נבדקו ארבע גרסאות באותה חלוקת train-test, עם k=5 ומשקל אחיד. השארת פרמטרי KNN קבועים אפשרה לבודד את השפעת PCA ואת השפעת SMOTE.

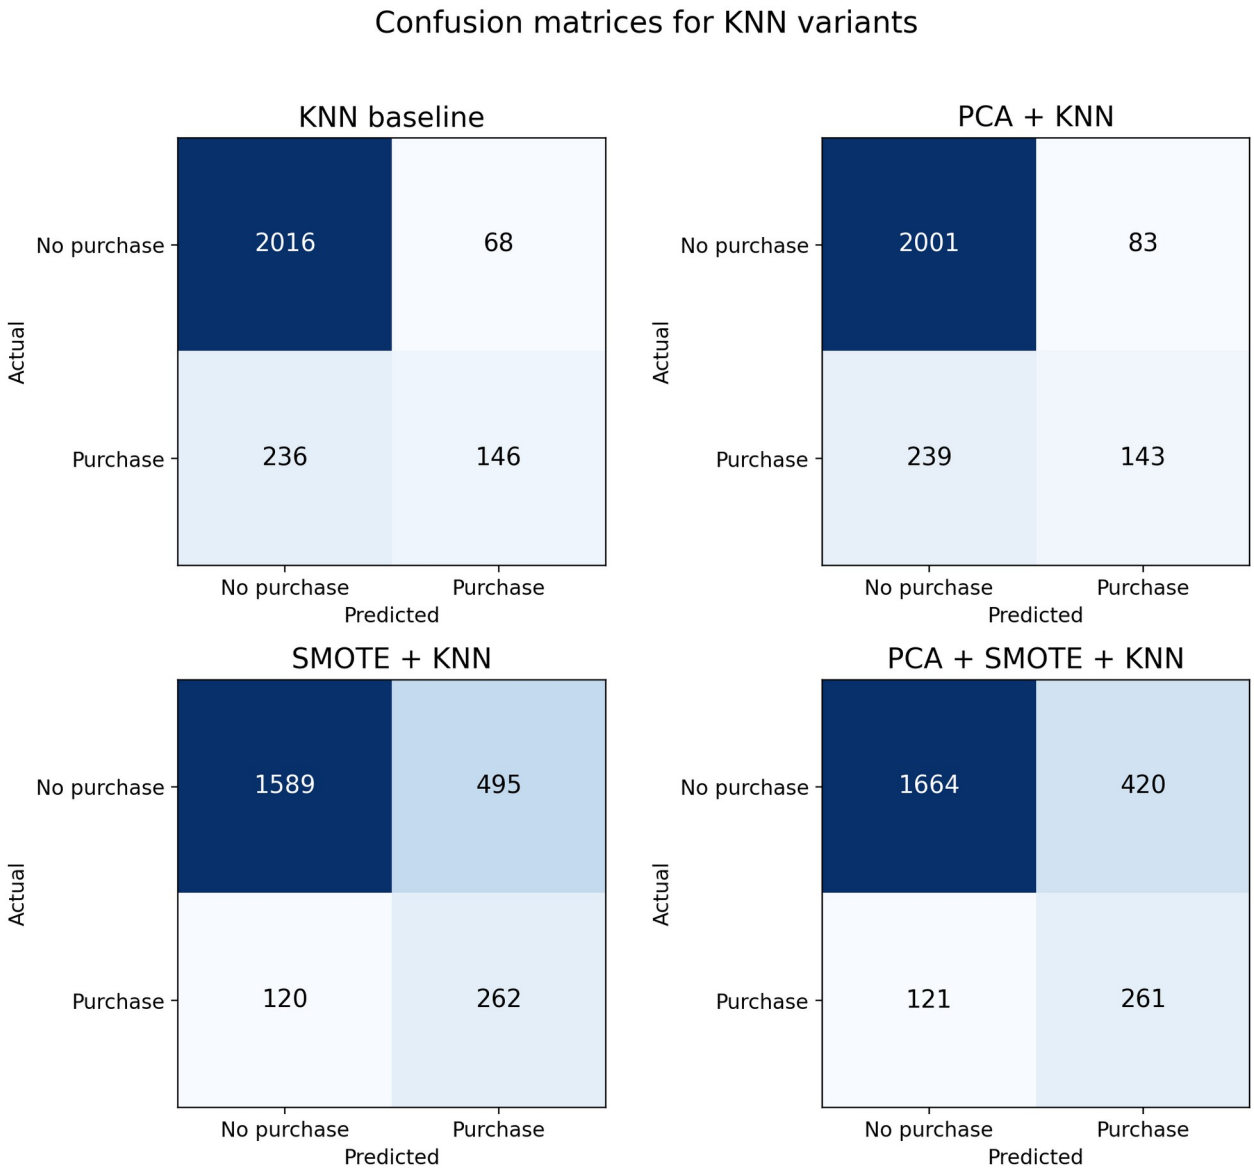
טבלה 9: השוואת **KNN, PCA** ו-**SMOTE**

מודל	Accuracy	Precision	Recall	F1	ROC AUC
KNN baseline	0.8767	0.6822	0.3822	0.4899	0.7633
PCA + KNN	0.8694	0.6327	0.3743	0.4704	0.7899
SMOTE + KNN	0.7506	0.3461	0.6859	0.4601	0.7810
PCA + SMOTE + KNN	0.7806	0.3833	0.6832	0.4911	0.7962



איור 19: השוואת המדדים בניסוי **KNN, PCA** ו-**SMOTE**

מה ניתן להסיק: PCA לבדו לא שיפר את F1 או את Recall. SMOTE העלה את Recall לכ-0.686 אך הוריד Precision ו-Accuracy. השילוב PCA-SMOTE-KNN שמר Recall גבוה והשיג F1 ו-ROC AUC טובים יותר מ-SMOTE ללא PCA.



איור 20: מטריצות בלבול של ארבע גרסאות **KNN**

> מה ניתן להסיק: המעבר ל-SMOTE מגדיל מאוד את מספר הרכישות המזוהות, אך גם את מספר ה-False Positives. הוספת PCA מפחיתה חלק מהתחזיות החיוביות השגויות ביחס ל-SMOTE בלבד, תוך שמירה כמעט מלאה על מספר ה-True Positives.

14.4 פירוש התוצאות

- **PCA** בלבד - לא שיפר את הסיווג. שונות גבוהה אינה בהכרח מידע מפריד למחלקה.
- **SMOTE** בלבד - שיפר מאוד Recall במחיר של Precision ו-Accuracy.
- **PCA + SMOTE** - יצר מרחב קומפקטי יותר ושיפר את האיזון לעומת SMOTE בלבד.
- בהשוואה ל-**Random Forest** - גם הגרסה המשולבת נותרה חלשה משמעותית ב-F1 וב-ROC AUC.

15. כוונן PCA, SMOTE ו-KNN

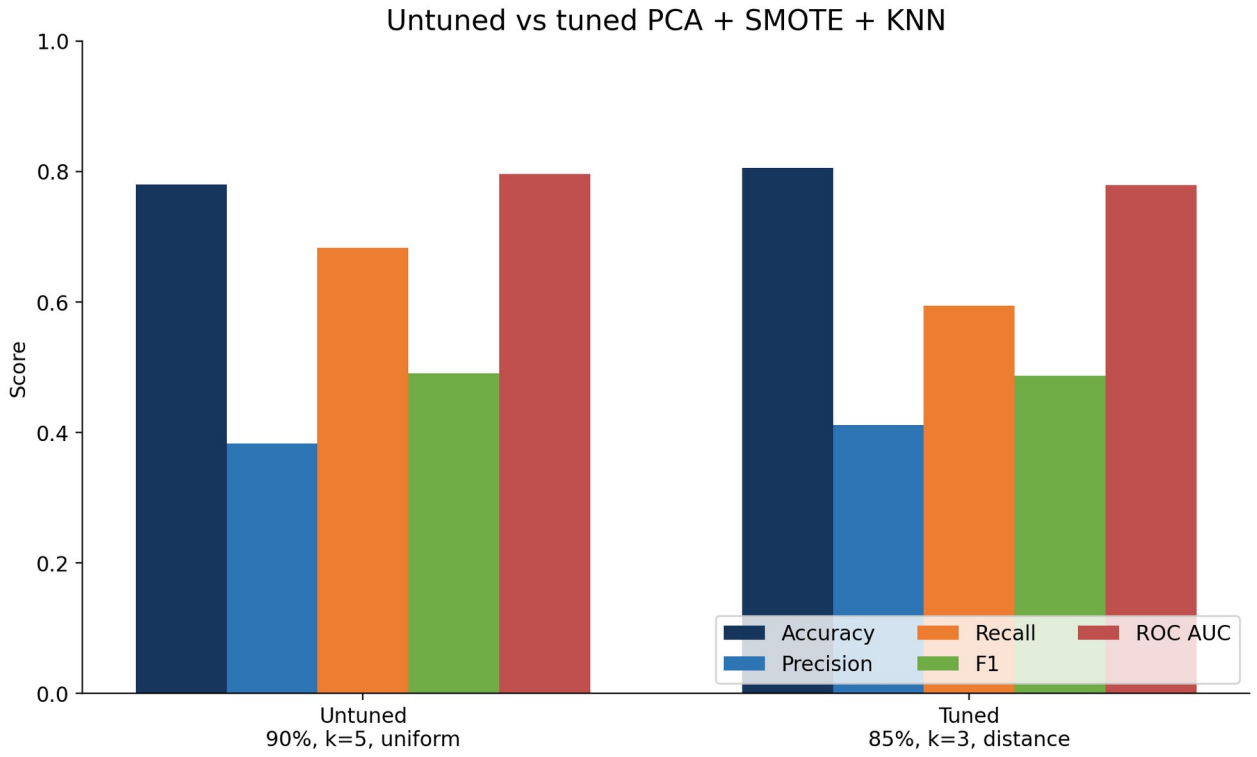
לאחר שהגרסה המשולבת נמצאה מבטיחה, בוצע Grid Search על שלושה יעדי שונות, שישה ערכי k ושתי שיטות משקל. בסך הכול נבדקו 36 שילובים בחמישה קיפולים - 180 התאמות מודל.

```
pca__n_components = [0.85, 0.90, 0.95]
classifier__n_neighbors = [3, 5, 7, 9, 11, 15]
classifier__weights = ["uniform", "distance"]
"scoring = "f1
```

הפרמטרים הטובים ביותר ב-Cross-Validation היו 85% שונות, 15 רכיבים, k=3 ו-"weights="distance", עם Mean CV F1 של 0.5355.

טבלה 10: המודל המשולב לפני ואחרי כוונן

מודל	Accuracy	Precision	Recall	F1	ROC AUC
ללא כוונן - 90%, k=5, uniform	0.7806	0.3833	0.6832	0.4911	0.7962
מכוונן - 85%, k=3, distance	0.8058	0.4120	0.5942	0.4866	0.7792



איור 21: **PCA-SMOTE-KNN** לפני ואחרי **Grid Search**

מה ניתן להסיק: המודל המכוונן העלה Accuracy ו-Precision, אך הוריד Recall, F1 ו-ROC AUC. מאחר

שהמטרה הייתה לשפר את F1, הכוונון לא הצליח על קבוצת הבדיקה.

התאמת יתר אפשרית: בחלק מהשילובים עם distance weighting התקבל mean_train_F1 של 1.0. ב-KNN דוגמת אימון יכולה להיות שכנה של עצמה במרחק אפס, ולכן ביצועי אימון מושלמים אינם מעידים על הכללה טובה. הפער מול validation ו-test מצביע על סיכון ל-overfitting.

16. דיון כולל, אתגרים ומגבלות

16.1 השוואה בין דפוסי המודלים

- **Random Forest** מאוזן - האיזון הכולל הטוב ביותר והמודל הנבחר.
- **Logistic Regression** ו-Recall גבוה, אך יותר False Positives.
- **KNN** בסיסי - Precision גבוה יחסית אך Recall נמוך מאוד.
- Recall **SMOTE-KNN -** גבוה במחיר של תחזיות חיוביות שגויות רבות.
- **AdaBoost** - ביצועים טובים, אך לא עבר את Random Forest.

16.2 אתגרים מרכזיים

- חוסר איזון משמעותי בין המחלקות.
- שילוב משתנים מספריים, בוליאניים וקטגוריאליים.
- עלייה מ-17 ל-75 מאפיינים לאחר One-Hot Encoding.
- מניעת דליפת מידע ב-scaling, PCA ו-SMOTE.
- בחירת מדד שאינו מוטה למחלקת הרוב.
- הבחנה בין שיפור ב-validation לבין שיפור אמיתי ב-test.

16.3 מגבלות הפרויקט

- המאגר אינו כולל מידע עשיר על היסטוריית הלקוח, מחיר המוצרים או תהליך התשלום.
- PageValues הוא מאפיין חזק מאוד ועלול לשקף מידע קרוב בזמן לרכישה; יש לבחון את זמינותו בזמן חיזוי אמיתי.
- Feature Importance של Random Forest אינה הסבר סיבתי ואינה מודדת כיוון השפעה.
- תוצאות הכוונון תלויות בחלוקה ובטווח הפרמטרים שנבחר.
- SMOTE מייצר דוגמאות מלאכותיות, ולכן יש לבדוק את התאמתו גם בהקשר עסקי ותפעולי.

16.4 כיווני המשך אפשריים

- בדיקת Precision-Recall AUC וכיול הסתברויות.
- בחירת סף לפי עלות עסקית מוגדרת של False Positive ו-False Negative.
- בדיקת Permutation Importance או SHAP להסבר מקומי וגלובלי.
- בדיקת מודלים נוספים רק אם הם מוסיפים שאלה מחקרית ברורה, ולא לצורך ריבוי מודלים בלבד.
- בדיקת יציבות התוצאות בכמה חלוקות או באמצעות Nested Cross-Validation.

1. ניתן לחזות כוונת רכישה ברמה טובה באמצעות מאפייני הביקור.
2. Accuracy לבדו מטעה: Dummy Classifier משיג כ-84.5% בלי לזהות אף רכישה.
3. Random Forest המאוזן הוא המודל המוביל עם F1=0.6634 ו-ROC AUC=0.9191.
4. איזון המחלקות העלה משמעותית את Recall ואת F1 של Random Forest.
5. PageValues הוא המאפיין הבולט ביותר, אך גם דפי מוצרים, ExitRates ו-BounceRates משמעותיים.
6. קיימת עונתיות ברורה ושיעור הרכישה גבוה במיוחד בנובמבר.
7. Grid Search ושינוי סף לא שיפרו את Random Forest לפי F1 על test.
8. PCA לשני ממדים הסביר רק כ-36% מהשונות ולא יצר הפרדה מלאה.
9. לצורך חיזוי, 20 רכיבים שמרו כ-90.8% מהשונות מתוך 75 מאפיינים מעובדים.
10. PCA לבדו לא שיפר את KNN.
11. SMOTE העלה את Recall של KNN מכ-0.382 לכ-0.686, במחיר של Precision ו-Accuracy.
12. PCA-SMOTE-KNN היה טוב יותר מ-SMOTE-KNN, אך לא עבר את Random Forest.
13. כוונון המודל המשולב לא שיפר את F1 על קבוצת הבדיקה.
14. ניסויים שלא שיפרו את התוצאה היו חשובים להבנת הפשרות, הכללת המודל וסכנת התאמת היתר.

> בחירה סופית: המודל הנבחר לפרויקט הוא Random Forest עם class_weight="balanced". גרסת KNN המועדפת בניסוי ההרחבה היא Preprocessing → PCA 90% → SMOTE → KNN עם 20 רכיבים, חמישה שכנים ומשקל אחיד.